


Контекст: платформа мониторинга Yandex Monium

1. Технические и продуктовые метрики — в одной платформе
2. Миллионы рядов появляются автоматически
3. Детекция должна работать на произвольном ряде



Аналог: Prometheus + Grafana + Loki + Tempo



3:08:02 / 7:57:00




Аномалии на временных рядах

Аномалия — значимое отклонение от ожидаемого паттерна


Здоровый временной ряд

Ряд придерживается своей формы



Временной ряд с аномалией


Произошло неожиданное отклонение от привычной формы



3:08:26 / 7:57:00



Почему пороговый алертинг не масштабируется




Порог не знает тренд
и сезонность



Слишком много ложных
срабатываний




Ручная настройка
не масштабируется



3:08:46 / 7:57:00



Адаптивный коридор вместо линии



Коридор нормы вместо
фиксированной линии



Тренд, сезонность,
выбросы и пропуски



Без ручной настройки
и предобучения



9



я про бэкенд



3:09:28 / 7:57:00



Нельзя просто взять ML-модель и положить в прод



01

Stateless

Нет истории и состояния
между вызовами

02


Zero-shot

Нет отдельной модели
под каждую метрику

03

Latency и стоимость

Секунды на CPU,
без GPU-кластера



10



я про бэкенд



3:09:45 / 7:57:00



Почему stateless?



- Пайплайн алертинга уже настроен и работает в масштабе Яндекса
- Работает по принципу: достал метрику, сравнил с правилом, кинул алерт
- Хранение состояния потребовало бы переписать весь пайплайн: отгрузка в метрик очередь, запись предсказаний, итеративное обновление детектора

11



я про
бэкенд



3:10:22 / 7:57:00



Попытка взять готовое: что предлагает индустрия

Классическое прогнозирование

ARIMA
Prophet
STL-декомпозиция
Spectral Residual

Предобученные нейросетевые модели

TimesFM
Chronos
Anomaly Transformer

12



я про
бэкенд



3:11:09 / 7:57:00



ARIMA и Prophet быстро или качественно — выбрать одно

Prophet: качественно, но медленно —
до 472 с. на ряд (AIOPS)

ARIMA: 1,5 с. на ряд (AIOPS),
но переобучается на аномалиях

Нет интерпретируемых границ нормы



Прогноз подстроился под выброс
Числа — из бенчмарка: 631 размеченный ряд, 5 датасетов

13



я про бэкенд



3:11:31 / 7:57:00



Foundation Models: исходная гипотеза

Гипотеза

Zero-shot прогноз без обучения под конкретную метрику

Что делали

Протестировали в парадигме stateless zero-shot

Что оценивали

Качество, время на ряд и пригодность выхода для границ нормы

ПРОВЕРЕННЫЕ МОДЕЛИ

Granite TTM

Chronos

TimesFM

PatchTST

14



+ 20 >

я про
бэкенд



3:12:19 / 7:57:00



Foundation Models: дорого

01

Полный прогон трансформера
на каждом шаге

TimesFM 17,7 с. на ряд против 1,5 с. у
авторегрессии — в 12 раз дольше



15



я про бэкенд



3:12:36 / 7:57:00



Foundation Models: нет пригодных границ


02

Zero-shot отдаёт слишком грубый
точечный прогноз

TimesFM на AIOPS: $F1 = 0,31$
против 0,74 у Stable AR



16



+ 5 >

я про бэкенд



3:12:56 / 7:57:00



Foundation Models: тяжёлая интеграция


03

Весы нужно держать в памяти
каждого инстанса

У TimesFM ~200 млн параметров —
лёгкий stateless-воркер превращается
в тяжёлый сервис



17



+ 10 >

я про бэкенд



3:13:07 / 7:57:00



ИТОГ РАЗДЕЛА 01

Если метрик много и все они разные, не ищите одну готовую модель — нужен общий способ получать границы нормы.



**я про
бэкенд**



3:14:01 / 7:57:00



02

Собственное решение: математика под наши ограничения

Проблема первая: как свести несопоставимые
модели к единому виду



я про
бэкенд



3:14:18 / 7:57:00



Зоопарк моделей

Разный формат выхода

Прогноз, бинарная метка
и скор нельзя сравнивать напрямую

20



я про
бэкенд

Я



3:14:21 / 7:57:00



Зоопарк моделей

Разная вычислительная
стоимость

От миллисекунд до секунд на ряд: пригодность
для прода нужно измерять в общем контуре

21



+ 15 >

я про
бэкенд

Я



3:14:44 / 7:57:00



Зоопарк моделей

Разная устойчивость

Пропуски, короткие ряды и нерегулярная сетка ломают реализации

22



я про
бэкенд



3:14:50 / 7:57:00



Зоопарк моделей

Ни один формат выхода
не пригоден для алерта
напрямую

Пользователю нужны границы нормы
в единицах метрики

23



я про
бэкенд

Я



3:15:03 / 7:57:00



Единый контракт: модель прогнозирует, пайплайн решает



- Модель строит прогноз
- Общий слой считает показатель аномалии и границы нормы
- Один интерфейс — сравнимые качество и скорость

24



я про бэкенд




3:15:25 / 7:57:00



Переводим предсказания в интервал: Z-тест

1. Прогноз модели: $\hat{X} = A(X)$
2. Остатки: $r_i = x_i - \hat{x}_i$
3. Робастная оценка разброса через медианное абсолютное отклонение: $\sigma = \text{MAD}(|r|) / \Phi^{-1}(0.75)$
4. Оценка аномальности точки: $z_i = |r_i| / \sigma$
5. Границы нормы: $C_t(\tau) = [x_t - \tau\sigma, x_t + \tau\sigma]$
Аномальность: $z_t > \tau \Leftrightarrow x_t \notin C_t(\tau)$



25



я про
бэкенд



3:15:53 / 7:57:00



Бэкбоун алгоритмы

- Чтобы построить интервал нужен прогноз: от Prophet / Chronos / Arima / ...
- Нужны быстрые и качественные алгоритмы
- Мы предложили два: Стабильная Авторегрессия и Сезонная Декомпозиция

26



я про
бэкэнд



Авторегрессия переобучается на аномалиях



Базовая AR на ряде с протяжённой аномалией.

Аномалия попадает в контекст

Прогноз подстраивается под неё

Интервал расширяется — деградация
пропадает

Прогноз строится по последним
 p наблюдениям

27



+ 10 >

я про бэкенд



3:17:16 / 7:57:00



Стабильная AR: контекст на скрытом состоянии



Коридор держит уровень и не учится на аномалии


Контекст строится не по сырому значению, а по скрытому состоянию

Доверие к точке: $w = 1/(1 + r(z_t))$

Скрытое состояние: $h_t = u_t(1 - w) + u_t w$

Сильная аномалия почти не попадает в контекст

28



я про бэкенд




3:17:44 / 7:57:00




Стабильная AR: адаптивная неопределённость

При резкой смене тренда σ_{res} временно растёт — коридор расширяется «ожидая» шум



Доверительный интервал расширяется при аномалии и нормализуется после неё

29



я про бэкенд



3:18:23 / 7:57:00




Сезонная декомпозиция: медианные фильтры

Бизнесу важно замечать плавные сезонные просадки или изменения тренда – нужен специальный алгоритм

Модель: $x_t = \mu_t + s_t + \varepsilon_t$

Тренд — линейная компонента

Сезонность — медиана по фазам соседних периодов вместо LOESS



Выявление аномального повышения метрики методом сезонной декомпозиции.

30



я про бэкенд




3:18:45 / 7:57:00



Сезонная дисперсия по фазам

Разброс считается отдельно для каждой фазы: σ_{seas}^i

Ночью и днём разная естественная волатильность



Динамический доверительный интервал повторяет сезонный профиль ряда.

31



я про бэкенд



3:19:19 / 7:57:00




Что получилось

Единый контракт для любой прогнозирующей модели

Визуальная интерпретация: границы нормы в единицах метрики



Новые алгоритмы: Stable AR и Seasonal Decomposition на CPU



32



я про бэкенд



ИТОГ РАЗДЕЛА 02

**Не прячьте решение внутри
модели: модель прогнозирует, а
общий слой считает остатки,
робастную сигму
и границы.**



**я про
бэкенд**



3:20:04 / 7:57:00



03

Методология оценки

Проблема вторая: как измерить качество детекции честно



+ 5 >

я про
бэкенд




3:20:11 / 7:57:00



На чём вообще тестировать?



Заказы доставки от ритейлера — сезонность и тренд



Использование RAM — смена уровня и дисперсии



Частота ошибок 5XX — редкие всплески счётчика



Созданные заказы в регионе — продуктовая сезонность

Разные частота, длина, пропуски и структура — нужен разнородный бенчмарк без априорных предположений

35



я про бэкенд




3:20:17 / 7:57:00




На чём вообще тестировать?




Заказы доставки от ритейлера — сезонность и тренд



Использование RAM — смена уровня и дисперсии



Частота ошибок 5XX — редкие всплески счётчика



Созданные заказы в регионе — продуктовая сезонность

Разные частота, длина, пропуски и структура — нужен разнородный бенчмарк без априорных предположений



3:20:39 / 7:57:00



35

Формальная постановка

Ряд: $X = (x_1, \dots, x_T)$

Экспертная разметка: $Y \in 0,1^T$

Алгоритм: $A: X \mapsto Y \in \mathbb{R}^T$

Цель: $\frac{1}{M} \sum_j \rho(A(X^{(j)}), Y^{(j)}) \rightarrow \max$

Без предобучения на наборе
и состояния между прогонами



Тестируем ровно тот режим, который поедет в прод

Train/test + подбор под ряд

Ряд не делится: модель проходит его целиком


Одна конфигурация на весь набор

Холодный старт +
единая конфигурация

Логируем качество и время обработки

Воспроизводимые прогоны
и версии конфигов

37



+ 25 >

я про бэкенд



3:21:14 / 7:57:00



Почему обычный F1 обманывает

$$F_1 = 2 \frac{Precision \times Recall}{Precision + Recall}$$

- Показывает, насколько хорошо находим аномалии, при этом не помечая лишнее
- Дисбаланс классов: аномалий несколько процентов
- Аномалия — сегмент, а не точка

38



я про
бэкенд



F1 с сегментной корректировкой

Хотя бы одна точка внутри сегмента → инцидент обнаружен.

Пропущенный интервал считается одной ошибкой.

Берём $F1_{best}$ по всем порогам или AUC-PR.

Истинные метки

0 0 1 1 1 0 0 1 1 1

Адаптивные истинные метки

0 0 1 0 0 1

Предсказанные scores

0.2 0.3 0.5 0.9 0.8 0.7 0.8 0.1 0.1 0.1

Предсказанные метки

0 0 0 1 1 1 1 0 0 0

Адаптивные предсказанные метки

0 0 1 1 1 0

Метод Revised Point Adjustment

39



я про
бэкенд

Наборы данных

Датасет	Рядов	Характер данных
AIOPS	29	Инфраструктурная KPI с минутной дискретизацией, точечные выбросы
NAB	10	AWS, клики, трафик, Twitter; точечные, трендовые и сезонные аномалии
TODS	15	Синтетика: пять контролируемых типов аномалий
WSD	210	Реальный KPI веб-сервиса, точечные аномалии
Yahoo	367	Реальные и синтетические ряды, точечные и контекстуальные выбросы
Итого	631	Единый протокол прогона на всех наборах

631 размеченный ряд · 5 публичных наборов · экспертная разметка

40



я про бэкенд



3:23:05 / 7:57:00



Результаты бенчмарка


Model	AIOPS	NAB	TODS	WSD	Yahoo	Time, s
Stable AR	0.74	0.71	0.78	0.83	0.95	0.48-4.7
Autoreg	0.75	0.64	0.70	0.83	0.91	0.12-1.5
Seasonal Dec.	0.61	0.73	0.66	0.82	0.84	0.06-2.2
Spectral Res.	0.77	0.66	0.76	0.85	0.93	0.04-0.6
Prophet	0.68	0.72	0.23	0.86	0.88	1.2-472
TimesFM	0.31	0.65	0.24	0.31	0.79	1.0-17.7

Превосходство статистики: DL (TimesFM) в stateless-режиме показывает F1 в 2-3 раза ниже при увеличении времени на порядок

Эффективность Stable AR: рост F_1^{best} с 0.91→0.95 (Yahoo), 0.64→0.71 (NAB). Устранено переобучение на выбросы.

Отсев базлайнов: Prophet нестабилен (0.23 на TODS), Spectral Res. исключен — отсутствие интервала в исходном пространстве.

41



я про бэкенд



3:23:39 / 7:57:00



А что на реальном потоке алертов?


Бенчмарк не отвечает, станет ли дежурному легче

Сетап: взяты дефолтные пороговые алерты, автоматически создаваемые на метрики деплоев, — около 1000 метрик. Поднята история их срабатываний за 35 дней. По тем же метрикам за тот же период прогнан детектор.

в 3.5 раза

сокращение числа
срабатываний

42



я про
бэкенд



3:24:13 / 7:57:00



ИТОГ РАЗДЕЛА 03

Качество детектора измеряйте в том режиме, в котором он поедет в прод: холодный старт, одна конфигурация, сегментный F1 и время.



**я про
бэкенд**



3:24:54 / 7:57:00



04

Путь в продакшен

От исследовательского стенда до сервиса под нагрузкой



я про
бэкенд



3:25:06 / 7:57:00



Первое, что стоит собрать, — исследовательский стенд

Главный цикл: параметр → реальный ряд → график
Streamlit + API мониторинга

Стенд стал общим языком с пользователями



итерация «параметр → график»
за минуты, без продового кода

45



я про бэкенд



3:25:13 / 7:57:00



Подбор конфигурации на реальных данных



Выбор ряда, модели и параметров

Сразу виден коридор и срабатывания

Проверка конфигурации на истории

Гипотезы проверялись до продового кода

46




я про бэкенд



3:25:30 / 7:57:00



Архитектура микросервиса



Python-библиотека фиксирует протокол: валидация, ресэмплинг, детекция, интерполяция результата

47



я про бэкенд



3:25:47 / 7:57:00



От стенда к сервису: продакшен-контур



48



я про
бэкенд



3:26:10 / 7:57:00



Что подавать в алгоритм для расчета алерта?



Вход: ~2 недели истории

Прогноз по всему куску — это контекст

Алерт считается только по новым точкам

49



я про бэкенд



3:26:38 / 7:57:00



Пользователю нельзя отдавать гиперпараметры

Внутри алгоритма

порядок AR (p)


ширина окна

коэффициент сглаживания

длина сезона (ℓ_s)

нормировка остатков

порог по z-оценке




Внутри — десяток параметров

Заставлять их подбирать —
неуважение к времени пользователя

Нужны параметры с понятным
поведением алерта

50



я про бэкенд



3:27:02 / 7:57:00




Threshold и Percentage

Threshold — ширина коридора нормы

τ : насколько сильно значение выходит за норму

Threshold: ширина коридора ($\tau = 1.5$ и 3.0)



Percentage — доля аномальных точек

Доля аномальных точек за последние 30 минут

Percentage: доля аномальных точек в окне



51



я про
бэкенд



3:27:13 / 7:57:00



Как выбирается модель

Stable Autoregression


Резкие пики и внезапный шум

Seasonal Decomposition

Плавные просадки и смена тренда

Модель можно переключить
при создании алерта

Дефолт — авторегрессия



52



я про
бэкенд



3:27:47 / 7:57:00



Что получилось по ресурсам

5 550

активных алертов
на боевом контуре

35


CPU — суммарная
утилизация всех инстансов


220 Гб

RAM на весь кластер
детектора

Сколько CPU понадобилось бы с другой моделью на том же потоке
(18,5 RPS × время ряда из бенчмарка)

Stable AR  ≈ 28 CPU

TimesFM  ≈ 330 CPU

Prophet  ≈ 700 CPU

Аппроксимация
из таймингов бенчмарка,
не продовый замер

53



я про бэкенд



3:28:05 / 7:57:00




Кейс: мониторинг качества Такси

- Операционные метрики: заказы, конверсии, время подачи
- 800+ городов · разные масштабы и сезонность
- Единый порог неприменим
- Одна конфигурация детектора на все метрики



Пример инцидента — резкий рост доли необработанных заказов

54



я про бэкенд



3:28:28 / 7:57:00



Ограничения



Редкие сезонные события: робастная статистика считает их за выбросы




Смена уровня после релиза → автоматический мьют



Праздники и разовые акции неизвестны сезонному профилю

55



я про бэкенд



3:29:31 / 7:57:00



Ограничения



Редкие сезонные события: робастная статистика считает их за выбросы



Смена уровня после релиза → автоматический мьют



Праздники и разовые акции неизвестны сезонному профилю

55



я про
бэкенд

ИТОГ РАЗДЕЛА 04

**До продакшена доходит не самая
сложная модель, а та, которую
можно быстро настроить,
объяснить
и масштабировать.**



**я про
бэкенд**



3:30:03 / 7:57:00



Один расчёт — три сценария применения

01

< - 5

Регулярный алертинг

По расписанию

02

Разбор инцидента
по клику

Интерактивно
на любом графике

03

Инструмент
для AI-агента

По запросу AI-агента

58



я про бэкенд

Я



3:30:31 / 7:57:00



Почему агенту нельзя просто «показать метрики»

288

точек в сутки
при шаге 5 минут

4 032


точки за две недели — и это
одна метрика одного сервиса

Текст забывает контекст и не даёт надёжного
численного анализа

```
1710340800, 512.34
1710341100, 498.12
1710341400, 505.77
1710341700, 521.03
...
1710357600, 524.26
```

~4000 точек одной
метрики текстом

59



я про
бэкенд



3:30:37 / 7:57:00



Подход через изображения графиков



стоимость ~ N метрик

Вердикт субагента

```
{ "metric": "orders.unprocessed_share", "selector":  
  {"city": "moscow"},  
  "is_anomalous": true, "severity": 0.87,  
  "interval": ["2026-03-14T10:15:00", "2026-03-  
14T11:40:00"],  
  "summary": "устойчивый рост доли необработанных  
заказов" }
```

60



я про бэкенд



3:30:54 / 7:57:00




Отдать агенту проверенный детектор



Пример ответа инструмента

```
{  
  "selector": {"city": "moscow"},  
  "period": ["2026-03-14", "2026-03-15"],  
  "anomalies": [  
    { "metric": "orders.unprocessed_share",  
      "severity": 0.87,  
      "duration_min": 85 },  
    { "metric": "couriers.active",  
      "severity": 0.41,  
      "duration_min": 20 }  
  ]  
}
```

61



я про бэкенд



3:31:22 / 7:57:00



Разделение ответственности

**Численный анализ —
детерминированному
коду, интерпретация
и выводы — модели.**

62



**я про
бэкенд**



3:31:50 / 7:57:00



Выводы



Зоопарк моделей
с несовместимым
выходом → блэкбокс
прогнозирует, общий
слой строит границы
нормы



Лабораторные метрики
обманывают →
продовый протокол:
холодный старт,
сегментный F1 и время



Дежурному нужна
простая настройка →
два параметра
с понятным
поведением алерта

63



я про бэкенд



3:32:01 / 7:57:00



ГЛАВНЫЙ ВЫВОД

**В stateless / zero-shot / CPU-
контуре робастная статистика
превосходит Foundation Models
по качеству и стоимости.**



**я про
бэкенд**



3:32:30 / 7:57:00



Материалы к докладу



Репозиторий
Демонстрационный
ноутбук с примером
реализации.



Tech Report
PDF с математическим
описанием.



65



+ 15 >

я про бэкенд



3:32:47 / 7:57:00

